

Отчёт по лабораторной работе №7

Введение в работу с данными

Козлов Всеволод Павлович НФИбд-02-22

Содержание

1	Цель работы	5
2	Задание	6
3	Выполнение лабораторной работы	7
4	Выводы	13
5	Список литературы	14

Список иллюстраций

3.1	Считывание данных	7
3.2	Описание датасета	8
3.3	Missing values	8
3.4	Кластеризация через k-mean	9
3.5	KNN	9
3.6	PCA	10
3.7	Линейная регрессия	10
3.8	Датапоинты	11
3.9	График регрессии	11
3.10	Графики акций	12

Список таблиц

1 Цель работы

Основной целью работы является специализированных пакетов Julia для обработки данных.

2 Задание

1. Используя Jupyter Lab, повторите примеры из раздела 7.2.
2. Выполните задания для самостоятельной работы (раздел 7.4).

3 Выполнение лабораторной работы

Считывание данных (рис. 3.1)

```
[3]: # 7.2.1.1 Считывание данных из CSV
P = CSV.File("programminglanguages.csv") |> DataFrame

# Функция для поиска года создания языка (без учёта регистра)
function language_created_year_v2(P, language::String)
    loc = findfirst(lowercase.(P[:, 2]) .== lowercase(language))
    return P[loc, 1]
end

# Пример вызова функции
language_created_year_v2(P, "julia")

[3]: 2012

[4]: # 7.2.1.2 Запись данных в файл
CSV.write("programming_languages_data2.csv", P)

[4]: "programming_languages_data2.csv"
```

Рис. 3.1: Считывание данных

Описание датасета (рис. 3.2)

```
[5]: # 7.2.1.3 Словарь
dict = Dict{Int64, Vector{String}}()
for i in 1:size(P, 1)
    year = P[i, 1]
    lang = P[i, 2]
    if year in keys(dict)
        push!(dict[year], lang)
    else
        dict[year] = [lang]
    end
end

dict[2003]

[5]: 2-element Vector{String}:
 "Groovy"
 "Scala"

[6]: # 7.2.1.5 RDatasets
iris = dataset("datasets", "iris")
typeof(iris)
describe(iris)

[6]: 5x7 DataFrame
  Row variable   mean   min   median   max   nmissing   eltype
   Symbol   Union... Any   Union... Any   Int64   DataType
-----
  1 SepalLength  5.84333  4.3    5.8     7.9         0   Float64
  2 SepalWidth   3.05733  2.0    3.0     4.4         0   Float64
  3 PetalLength  3.758     1.0    4.35    6.9         0   Float64
  4 PetalWidth   1.19933  0.1    1.3     2.5         0   Float64
```

Рис. 3.2: Описание датасета

Missing values (рис. 3.3)

```
[8]: # 7.2.1.6 Работа с Missing Values
foods = ["apple", "cucumber", "tomato", "banana"]
calories = [missing, 47, 22, 105]
prices = [0.85, 1.6, 0.8, 0.6]
dataframe_calories = DataFrame(item = foods, calories = calories)
dataframe_prices = DataFrame(item = foods, price = prices)

# Исправленная строка: используем innerjoin вместо join
DF = innerjoin(dataframe_calories, dataframe_prices, on = :item)

mean(skipmissing(calories))

[8]: 58.0
```

Рис. 3.3: Missing values

Кластеризация через k-mean (рис. 3.4)




Рис. 3.4: Кластеризация через k-mean

KNN (рис. 3.5)

```
[12]: # 7.2.2.2 Метод k ближайших соседей
knearest = 10
id = 70
point = X[:, id]
kdtree = KDTree(X)
idxs, dists = knn(kdtree, point, knearest, true)
scatter(filter_houses[!, :latitude], filter_houses[!, :longitude])
scatter!(filter_houses[idxs, :latitude], filter_houses[idxs, :longitude])
cities = filter_houses[idxs, :city]
```

```
[12]: 10-element PooledArrays.PooledVector{String15, UInt32, Vector{UInt32}}:
 "SACRAMENTO"
 "ELK GROVE"
 "SACRAMENTO"
 "SACRAMENTO"
 "SACRAMENTO"
 "SACRAMENTO"
 "ELK GROVE"
 "ELK GROVE"
 "ELK GROVE"
 "ELK GROVE"
```

Рис. 3.5: KNN

PCA (рис. 3.6)




Рис. 3.6: PCA

Линейная регрессия (рис. 3.7)




Рис. 3.7: Линейная регрессия

Датапоинты (рис. 3.8)

```
[22]: # Задание 2: Кластеризация набора Iris
iris = dataset("datasets", "iris")
iris_matrix = Matrix(iris[, 1:4])
k_iris = 3
C_iris = kmeans(iris_matrix, k_iris)
scatter(iris_matrix[1, :], iris_matrix[2, :], group = C_iris.assignments, legend = false)
```




Рис. 3.8: Датапоинты

График регрессии (рис. 3.9)

```
[23]: # Задание 3: Линейная регрессия (часть 1)
X = randn(1000, 3)
a0 = rand(3)
y = X * a0 + 0.1 * randn(1000)
X2 = hcat(ones(size(X, 1)), X)
a_hat = X2 \ y
println("Оценка коэффициентов: ", a_hat)
```

Оценка коэффициентов: [0.003255403542677329, 0.19813363923539568, 0.5488655528083908, 0.8750372045153417]

```
[24]: # Задание 3: Линейная регрессия (часть 2)
X = rand(100)
y = 2 .* X + 0.1 .* randn(100)
a, b = find_best_fit(X, y)
scatter(X, y, leg = false, title = "График регрессии", xlabel = "X", ylabel = "y")
plot!(X, a .* X .+ b, color = :red)
```




Рис. 3.9: График регрессии

Графики акций (рис. 3.10)

```

# Схема d: Модель ценообразования биомассы на основе
function createPath(S::Float64, r::Float64, sigma::Float64, T::Float64, n::Int64)
    h = T / n
    u = exp((r + sigma * sqrt(h)) * h)
    d = exp((r - sigma * sqrt(h)) * h)
    p_star = ((exp(r * h) - d) / (u - d))
    path = zeros(n + 1)
    path[1] = S
    for t in 2:n + 1
        path[t] = path[t - 1] * (rand() < p_star ? u : d)
    end
    return path
end

S, T, n, sigma, r = 100.0, 1.0, 10000, 0.3, 0.08
path = createPath(S, r, sigma, T, n)
plot(0:n, path, title = "Траектория цен акций", xlabel = "Время", ylabel = "Цена", log = false)

# Генерация 10 траекторий
paths = [createPath(S, r, sigma, T, n) for _ in 1:10]
plot(0:n, paths, title = "10 траекторий цен акций", xlabel = "Время", ylabel = "Цена", legend = false)

```




Рис. 3.10: Графики акций

4 Выводы

Освоил специализированные пакеты Julia для обработки данных.

5 Список литературы

1. Julia 1.5 Documentation. — 2020. — URL: <https://docs.julialang.org/en/v1/>.
2. Klok H.,Nazarathy Y. Statistics with Julia: Fundamentals for Data Science,Machine Learning and Artificial Intelligence. — 2020. — URL: <https://statisticswithjulia.org/>.
3. Ökten G. First Semester in Numerical Analysis with Julia. — Florida State University, 2019. — DOI: 10.33009/jul.
4. Антонюк В. А. Язык Julia как инструмент исследователя. — М. : Физический факультет МГУ им. М. В. Ломоносова, 2019.
5. Шиндин А. В. Язык программирования математических вычислений Julia. Базовое руководство. — Нижний Новгород : Нижегородский госуниверситет, 2016.